Desafio Técnico RMI

Documento de Rastreio da Solução

Passo a passo do que foi construído: arquivo por arquivo, o que significa, como foi feito, características e exemplo real de cada tabela. Inclui a matriz de conformidade (o que foi pedido, o que atendemos e o que ficou pendente).

Autor	Matheus Bianco
Projeto	desafio-rmi-ds
Como ler	Use como checklist de revisão e mapa para novos insights.

> **Como os exemplos foram gerados**
>
> As amostras e contagens de cada model foram extraídas simulando o pipeline no DuckDB sobre os Parquet locais (idênticos ao bucket, verificado por checksum MD5). Refletem o que o dbt produz no BigQuery; os IDs hexadecimais aparecem truncados por espaço.

Sumário

1. Conformidade: o que foi pedido x o que foi entregue
2. Visão geral do pipeline e mapa de arquivos
3. Camada de fontes (dados brutos)
4. Camada de staging
5. Camada intermediate
6. Camada de marts
7. Painel de resultados (visualização dos marts)
8. Seeds, macros, testes, CI e scripts
9. Decisões e achados (rastreabilidade do raciocínio)
10. O que NÃO foi feito e pendências

Anexo: como os números foram verificados

1. Conformidade: o que foi pedido x o que foi entregue

Legenda de status: **OK** (atendido), **PARCIAL** (feito, com ressalva) e **PENDENTE** (não feito).

Parte 1: Projeto dbt e Modelagem

Item pedido	Status	Onde / observação
Projeto dbt configurado (dbt_project.yml, sources, estrutura)	OK	dbt_project.yml, packages.yml, sources definidas
Staging para >=4 tabelas (limpeza, tipagem, nulos, schema.yml)	OK	5 tabelas em staging + _educacao__models.yml
Intermediate >=1 combinando fontes	OK	2 models intermediate
Mart >=1 respondendo pergunta de gestor + schema.yml	OK	2 marts (table) + breve análise no README
dbt run executa sem erros	OK	dbt build no BigQuery (projeto exerciciodesafio): 9 models criados, 0 erros

Parte 2: Testes e Qualidade

Item pedido	Status	Onde / observação
Testes genéricos (unique, not_null, accepted_values, relationships)	OK	Nos schema.yml de staging, intermediate e marts
>=2 testes singular / customizados de regra de negócio	OK	3 testes em tests/ + 1 teste genérico customizado
dbt test passando	OK	PASS=62, WARN=1 (órfãos de turma, planejado), ERROR=0

Parte 3: Documentação e Análise

Item pedido	Status	Onde / observação
README (setup, lineage, decisões, trade-offs)	OK	README.md
Análise exploratória (opcional / diferencial)	OK	notebooks/eda.ipynb

Diferenciais sugeridos

Diferencial	Status	Observação
dbt packages	PARCIAL	dbt_utils usado; dbt_expectations e codegen declarados mas não usados em testes
freshness nas sources	OK	Configurado (baseado em metadados)
tags	OK	Tags por camada no dbt_project.yml
exposures	OK	Exposure do painel de gestão
hooks	PENDENTE	Não utilizado
data contracts	PENDENTE	Listado como próximo passo
CI com dbt build (GitHub Actions)	PARCIAL	Workflow pronto; roda de fato após configurar secrets do GCP

2. Visão geral do pipeline e mapa de arquivos

O fluxo: dados brutos no BigQuery (raw) -> **staging** (limpeza, 1 view por fonte) -> **intermediate** (combinações e métricas) -> **marts** (tabelas finais de consumo). Testes e documentação acompanham cada camada.

Fontes (raw)	Staging (view)	Intermediate (ephemeral)	Marts (table)
aluno	stg_educacao__alunos	int_educacao__aluno_frequencia	mart_educacao__absenteismo_regiao
escola	stg_educacao__escolas	int_educacao__aluno_desempenho	mart_educacao__desempenho_por_turma
turma	stg_educacao__matriculas		
avaliacao	stg_educacao__avaliacoes		
frequencia	stg_educacao__frequencia		

Todos os arquivos do projeto

Arquivo	Formato	Papel
dbt_project.yml	YAML	Configuração central: materializações, tags, vars de negócio
packages.yml	YAML	Pacotes dbt (dbt_utils, dbt_expectations, codegen)
profiles.yml.example	YAML	Modelo de conexão ao BigQuery (dev e ci)
requirements.txt	texto	Dependências Python
.gitignore	texto	Ignora dados, credenciais, artefatos
scripts/load_to_bigquery.py	Python	Carrega os Parquet do bucket para o BigQuery
scripts/load_to_bigquery.sh	Shell	Mesma ingestão via bq CLI
seeds/seed_educacao__disciplinas.csv	CSV	De/para de código de disciplina
macros/nome_disciplina.sql	SQL/Jinja	Traduz código de disciplina (DRY)
macros/generic_tests/test_proporcao_nulos_abaixo_de.sql	SQL/Jinja	Teste genérico customizado
models/staging/educacao/*.sql	SQL	5 models de limpeza
models/staging/educacao/_educacao__sources.yml	YAML	Fontes + freshness
models/staging/educacao/_educacao__models.yml	YAML	Descrições e testes do staging
models/intermediate/educacao/*.sql	SQL	2 models de métricas
models/marts/educacao/*.sql	SQL	2 marts de consumo
models/marts/educacao/_marts_educacao__exposures.yml	YAML	Exposure (painel)
tests/*.sql	SQL	3 testes singular de regra de negócio
notebooks/eda.ipynb	Jupyter	Análise exploratória
.github/workflows/ci.yml	YAML	CI (dbt build)
README.md	Markdown	Documentação técnica
docs/Desafio-RMI-Guia-101.pdf	PDF	Guia didático
docs/Desafio-RMI-Rastreio.pdf	PDF	Este documento
docs/amostras/*	CSV/XLSX	Amostras das tabelas brutas

3. Camada de fontes (dados brutos)

São as 5 tabelas Parquet do bucket `gs://case_vagas/rmi`, carregadas para um dataset `raw` no BigQuery. No dbt elas são declaradas como `sources`. Abaixo, cada uma com exemplo e características.

Fonte: aluno

Arquivo	gs://case_vagas/rmi/aluno
Formato	Parquet
Grão (1 linha =)	um aluno
Linhas	97.044

O que é / significa: Cadastro de alunos anonimizado (faixa etária, bairro em hash).

Como foi feito: Carregada direto do bucket para o BigQuery. id_aluno é BYTES (hash de 17 bytes).

Características e qualidade: 97.044 alunos únicos. bairro tem ~0,07% de nulos. id_aluno exibido aqui em hexadecimal.

Exemplo (amostra real)

id_aluno	id_turma	faixa_etaria	bairro
6ef3cf7d632f05b9…	-877530803406099…	15-17	<NA>
7ff590499207fd44…	-843312604371786…	15-17	<NA>
95c687bf2f2f9ba2…	-834474510557936…	6-10	<NA>

Colunas

Coluna	Tipo	Descrição
id_aluno	BYTES	ID do aluno (hash). Vira hexadecimal no staging.
id_turma	INT64	Turma de matrícula.
faixa_etaria	STRING	0-5, 6-10, 11-14, 15-17, 18+.
bairro	INT64	Hash do bairro (com nulos).

Fonte: escola

Arquivo	gs://case_vagas/rmi/escola
Formato	Parquet
Grão (1 linha =)	uma escola
Linhas	1.558

O que é / significa: Cadastro de unidades escolares.

Como foi feito: Carregada direto do bucket. Chaves em hash.

Características e qualidade: 1.558 escolas únicas, em 169 bairros distintos. Sem nulos relevantes.

Exemplo (amostra real)

id_escola	bairro
-868131367327353…	-898312475417451…
-397992739025987…	-897824296491824…
-72326310223927215	-897824296491824…

Colunas

Coluna	Tipo	Descrição
id_escola	INT64	ID da escola (hash).
bairro	INT64	Hash do bairro da escola.

Fonte: turma

Arquivo	gs://case_vagas/rmi/turma
Formato	Parquet
Grão (1 linha =)	um aluno (matrícula)
Linhas	97.044

O que é / significa: Apesar do nome, é a tabela de MATRÍCULAS: liga aluno a turma. Não traz série nem turno.

Como foi feito: Carregada direto do bucket. Uma linha por aluno.

Características e qualidade: 97.044 linhas (1 por aluno), 17.311 turmas. ano sempre 2000 (anonimizado).

Exemplo (amostra real)

ano	id_turma	id_aluno
2000	-921968794006910…	5ab32084de60a5c6…
2000	-921968794006910…	98e9bda2066bff43…
2000	-921936778406196…	090cadef70c11f3b…

Colunas

Coluna	Tipo	Descrição
ano	INT64	Ano letivo (fixo 2000).
id_turma	INT64	Turma.
id_aluno	BYTES	Aluno matriculado.

Fonte: avaliacao

Arquivo	gs://case_vagas/rmi/avaliacao
Formato	Parquet
Grão (1 linha =)	um aluno/turma/bimestre
Linhas	221.687

O que é / significa: Notas por bimestre em formato LARGO (uma coluna por disciplina). Contém também a frequência geral do bimestre (campo com variância, usado no absenteísmo).

Como foi feito: Carregada direto do bucket. Precisa de UNPIVOT no staging para virar formato longo.

Características e qualidade: 221.687 linhas. disciplina_3 (Inglês) 100% nula. frequência preenchida em ~99%. ~34 duplicatas de grão.

Exemplo (amostra real)

id_aluno	id_turma	frequencia	bimestre	disciplina_1	disciplina_2	disciplina_3	disciplina_4
42de8f7efaad9cb5…	8252629566642795…	(nulo)	3	0.04	5.04	(nulo)	0.04
be57e2ed4b4edd46…	-201093154297847…	(nulo)	2	0.1	0.1	(nulo)	(nulo)
05442dec5c3e67a1…	-698051562976163…	(nulo)	3	0.06	0.06	(nulo)	5.06

Colunas

Coluna	Tipo	Descrição
id_aluno	BYTES	Aluno.
id_turma	INT64	Turma.

Coluna	Tipo	Descrição
frequencia	FLOAT64	Frequência geral do bimestre (0-100, com sinal).
bimestre	STRING	1 a 4.
disciplina_1..4	FLOAT64	Notas: Português, Ciências, Inglês, Matemática.

Fonte: frequencia

Arquivo	gs://case_vagas/rmi/frequencia
Formato	Parquet
Grão (1 linha =)	aluno/turma/escola/período/disciplina
Linhas	2.727.684

O que é / significa: Registros de frequência por período e disciplina. É a maior tabela.

Como foi feito: Carregada direto do bucket. Datas como texto; anonimizadas no ano 2000.

Características e qualidade: 2,7 milhões de linhas. Percentual travado entre 97% e 100% (sem variância). id_turma com ~12% de órfãos; id_aluno e id_escola conciliam 100%. ~2,6 mil duplicatas.

Exemplo (amostra real)

id_escola	id_aluno	id_turma	data_inicio	data_fim	disciplina	frequencia
5780900243316271…	8c69678f3c9cdafe…	4858351103481648…	2000-08-01	2000-08-31	disciplina_3	100.0
5780900243316271…	8c69678f3c9cdafe…	4858351103481648…	2000-08-01	2000-08-31	disciplina_1	100.0
5780900243316271…	8c69678f3c9cdafe…	4858351103481648…	2000-08-01	2000-08-31	disciplina_4	100.0

Colunas

Coluna	Tipo	Descrição
id_escola	INT64	Escola.
id_aluno	BYTES	Aluno.
id_turma	INT64	Turma (~12% órfãos).
data_inicio/fim	STRING	Período (ano 2000).
disciplina	STRING	disciplina_1..4.
frequencia	FLOAT64	Percentual (97-100).

4. Camada de staging

Uma view por fonte. Objetivo: limpar, renomear, tipar e padronizar, sem lógica de negócio. Materializadas como **view** (leves, sempre refletem a fonte).

stg_educacao__alunos

Arquivo	models/staging/educacao/stg_educacao__alunos.sql
Formato	SQL (view)
Grão (1 linha =)	um aluno
Linhas	97.044

O que é / significa: Dimensão de alunos limpa.

Como foi feito: Converte id_aluno de BYTES para STRING hexadecimal (to_hex), renomeia colunas e aplica nullif/trim na faixa etária.

Características e qualidade: Chave aluno_id única e não nula (testado).

Exemplo (amostra real)

aluno_id	turma_id	faixa_etaria	bairro_id
6ef3cf7d632f05b9…	-877530803406099…	15-17	<NA>
7ff590499207fd44…	-843312604371786…	15-17	<NA>
95c687bf2f2f9ba2…	-834474510557936…	6-10	<NA>

Colunas

Coluna	Tipo	Descrição
aluno_id	STRING	Hex do aluno (chave).
turma_id	INT64	Turma.
faixa_etaria	STRING	Faixa etária.
bairro_id	INT64	Bairro (hash).

stg_educacao__escolas

Arquivo	models/staging/educacao/stg_educacao__escolas.sql
Formato	SQL (view)
Grão (1 linha =)	uma escola
Linhas	1.558

O que é / significa: Dimensão de escolas limpa.

Como foi feito: Renomeia as colunas para o padrão do projeto.

Características e qualidade: escola_id única e não nula (testado).

Exemplo (amostra real)

escola_id	bairro_id
-868131367327353…	-898312475417451…
-397992739025987…	-897824296491824…
-72326310223927215	-897824296491824…

Colunas

Coluna	Tipo	Descrição
escola_id	INT64	Chave da escola.
bairro_id	INT64	Bairro da escola.

stg_educacao__matriculas

Arquivo	models/staging/educacao/stg_educacao__matriculas.sql
Formato	SQL (view)
Grão (1 linha =)	um aluno/turma
Linhas	97.044

O que é / significa: Matrículas (origem: fonte turma), renomeada para refletir a semântica real.

Como foi feito: Converte id_aluno para hex e renomeia ano para ano_letivo.

Características e qualidade: aluno_id único (1 matrícula por aluno); ano_letivo sempre 2000 (testado).

Exemplo (amostra real)

aluno_id	turma_id	ano_letivo
5ab32084de60a5c6…	-921968794006910…	2000
98e9bda2066bff43…	-921968794006910…	2000
090cadef70c11f3b…	-921936778406196…	2000

Colunas

Coluna	Tipo	Descrição
aluno_id	STRING	Aluno.
turma_id	INT64	Turma.
ano_letivo	INT64	Ano (2000).

stg_educacao__frequencia

Arquivo	models/staging/educacao/stg_educacao__frequencia.sql
Formato	SQL (view)
Grão (1 linha =)	aluno/turma/escola/período/disciplina
Linhas	2.725.108

O que é / significa: Frequência limpa e deduplicada.

Como foi feito: Converte datas (texto para date), traduz o código de disciplina para nome (macro), e remove duplicatas de grão com row_number().

Características e qualidade: Grão único após dedup (testado). percentual_frequencia entre 0 e 100.

Exemplo (amostra real)

escola_id	aluno_id	turma_id	periodo_data_inicio	periodo_data_fim	disciplina_codigo	disciplina	percentual_frequencia
6973142898455895…	2805d05fb9a0aa99…	6948511700444414…	2000-04-01 00:00…	2000-04-30 00:00…	disciplina_2	Ciências	99.88888888888889
6724308541920830…	887dc35cdc7473f5…	-829775390586300…	2000-04-01 00:00…	2000-04-30 00:00…	disciplina_3	Inglês	99.88888888888889
4953738070328139…	c024e97387149768…	-252800000916460…	2000-04-01 00:00…	2000-04-30 00:00…	disciplina_3	Inglês	99.88888888888889

Colunas

Coluna	Tipo	Descrição
escola_id	INT64	Escola.
aluno_id	STRING	Aluno.
turma_id	INT64	Turma.
periodo_data_inicio/fim	DATE	Período.

Coluna	Tipo	Descrição
disciplina_codigo	STRING	disciplina_1..4.
disciplina	STRING	Nome legível.
percentual_frequencia	FLOAT64	0-100.

stg_educacao__avaliacoes

Arquivo	models/staging/educacao/stg_educacao__avaliacoes.sql
Formato	SQL (view)
Grão (1 linha =)	aluno/turma/bimestre/disciplina
Linhas	886.612

O que é / significa: Notas normalizadas de LARGO para LONGO (uma linha por disciplina).

Como foi feito: Aplica UNPIVOT (mantendo nulos) sobre disciplina_1..4, traduz o nome, carrega a frequência do bimestre e remove duplicatas de grão.

Características e qualidade: nota pode ser nula (ausência legítima). Inclui a coluna frequencia_bimestre_origem (fonte do absenteísmo).

Exemplo (amostra real)

aluno_id	turma_id	bimestre	frequencia_bimestre_origem	disciplina_codigo	disciplina	nota
3c94771b67b267f3…	-752089213310887…	3	(nulo)	disciplina_1	Português	0.02
c625c279fda4bab1…	-316599173130790…	1	(nulo)	disciplina_1	Português	0.2
ae4c44708e0df5a2…	-326859972218936…	2	(nulo)	disciplina_1	Português	(nulo)

Colunas

Coluna	Tipo	Descrição
aluno_id	STRING	Aluno.
turma_id	INT64	Turma.
bimestre	INT64	1 a 4.
frequencia_bimestre_origem	FLOAT64	Freq. geral do bimestre.
disciplina_codigo	STRING	Código.
disciplina	STRING	Nome.
nota	FLOAT64	0-10 ou nula.

5. Camada intermediate

Combina as fontes limpas e cria métricas por aluno. Materializada como **ephemeral** (vira CTE embutida nos marts, sem criar tabela física).

int_educacao__aluno_frequencia

Arquivo	models/intermediate/educacao/int_educacao__aluno_frequencia.sql
Formato	SQL (ephemeral)
Grão (1 linha =)	um aluno
Linhas	97.044

O que é / significa: Frequência consolidada por aluno. A frequência COM SINAL vem do campo de frequência da avaliação; a da tabela frequencia entra como contraste. Marca o absenteísmo crônico.

Como foi feito: Junta por aluno_id (chave confiável). Média bimestral da avaliação, média por registro da tabela frequencia, e escola predominante (maior contagem de registros).

Características e qualidade: 1 linha por aluno. flag_absenteismo_cronico = media_frequencia < 75. media_frequencia nula para alunos sem avaliação.

Exemplo (amostra real)

aluno_id	faixa_etaria	escola_id	n_bimestres_com_frequencia	media_frequencia	media_frequencia_registros	flag_absenteismo_cronico
eb0505f3a02a8cbb…	15-17	1430979552737434…	4	100.0	99.97	False
594185e2185ed8ac…	15-17	3430482404341375…	4	93.36	99.88	False
86ebcea7526ec27c…	15-17	3046701485704549…	4	96.8	99.96	False

Colunas

Coluna	Tipo	Descrição
aluno_id	STRING	Aluno.
faixa_etaria	STRING	Faixa.
escola_id	INT64	Escola predominante.
media_frequencia	FLOAT64	Média bimestral (com sinal).
media_frequencia_registros	FLOAT64	Contraste (tabela frequencia).
flag_absenteismo_cronico	BOOL	média < 75%.

int_educacao__aluno_desempenho

Arquivo	models/intermediate/educacao/int_educacao__aluno_desempenho.sql
Formato	SQL (ephemeral)
Grão (1 linha =)	um aluno/turma
Linhas	58.374

O que é / significa: Desempenho acadêmico consolidado por aluno, com médias por disciplina.

Como foi feito: A partir das avaliações (ignorando notas nulas), calcula média geral e média por disciplina.

Características e qualidade: media_geral de 0 a 10. flag_aprovado_media = média >= 6. Inglês fica nulo (sem notas).

Exemplo (amostra real)

aluno_id	turma_id	n_notas	media_geral	media_portugues	media_ciencias	media_matematica	flag_aprovado_media
862ebceaf6b11d93…	-335174699762613…	12	6.85	6.9	6.85	6.82	True
865aae995864408e…	725046935882013 6…	12	5.9	6.89	5.07	5.74	False
872d32ff25c3b810…	-389380279141165…	12	4.19	3.72	4.84	4.01	False

Colunas

Coluna	Tipo	Descrição
aluno_id	STRING	Aluno.
turma_id	INT64	Turma.
n_notas	INT64	Qtd. de notas.
media_geral	FLOAT64	0-10.
media_portugues/ciencias/matematica	FLOAT64	Por disciplina.
flag_aprovado_media	BOOL	média >= 6.

6. Camada de marts

As tabelas finais, que respondem perguntas de gestor. Materializadas como **table** para consulta rápida.

mart_educacao__absenteismo_regiao

Arquivo	models/marts/educacao/mart_educacao__absenteismo_regiao.sql
Formato	SQL (table)
Grão (1 linha =)	uma escola
Linhas	521

O que é / significa: Taxa de absenteísmo crônico (frequência média bimestral < 75%) por escola e região.

Como foi feito: Agrega int_aluno_frequencia por escola/bairro; usa a frequência com sinal para o flag; expõe também a frequência por registro como contraste.

Características e qualidade: Resultado acionável: ~10,4% de absenteísmo geral, variando de 0% a 33% entre escolas.

Exemplo (amostra real)

bairro_id	escola_id	n_alunos	n_alunos_com_frequencia	n_alunos_absenteismo_cronico	taxa_absenteismo_cronico	media_frequencia_regiao
5.29067120211024…	8.14279608371840…	31.0	24.0	8.0	0.3333	81.36
-2.3465961426155…	-8.8783899250083…	45.0	30.0	7.0	0.2333	84.38
5.29067120211024…	8.72183535866965…	30.0	22.0	5.0	0.2273	80.85

Colunas

Coluna	Tipo	Descrição
bairro_id	INT64	Região.
escola_id	INT64	Escola (chave).
n_alunos	INT64	Alunos da escola.
n_alunos_absenteismo_cronico	INT64	Qtd. com absenteísmo.
taxa_absenteismo_cronico	FLOAT64	Proporção 0-1.
media_frequencia_regiao	FLOAT64	Média da escola.

mart_educacao__desempenho_por_turma

Arquivo	models/marts/educacao/mart_educacao__desempenho_por_turma.sql
Formato	SQL (table)
Grão (1 linha =)	uma turma
Linhas	17.311

O que é / significa: Desempenho médio por turma cruzado com o tamanho da turma.

Como foi feito: Calcula o tamanho da turma (matrículas) e junta com as médias de desempenho por turma.

Características e qualidade: Permite analisar tamanho x desempenho. Turmas sem avaliação ficam com médias nulas.

Exemplo (amostra real)

turma_id	n_alunos_matriculados	faixa_tamanho_turma	n_alunos_avaliados	media_geral_turma	taxa_aprovacao_media
-479664583789228…	118	05. Mais de 30	109	4.0	0.0917
-655873215542861…	85	05. Mais de 30	47	4.75	0.3404
7479153708478109…	75	05. Mais de 30	66	5.78	0.3939

Colunas

Coluna	Tipo	Descrição
turma_id	INT64	Turma (chave).
n_alunos_matriculados	INT64	Tamanho.
faixa_tamanho_turma	STRING	Faixa de tamanho.
media_geral_turma	FLOAT64	Média 0-10.
taxa_aprovacao_media	FLOAT64	Proporção aprovados.

7. Painel de resultados (visualização dos marts)

Os marts alimentam um painel executivo de gestão (HTML + Chart.js, também publicado como web app em Google Apps Script). Ele resume os indicadores da rede em uma leitura rápida: KPIs, o contraste entre as duas frequências, a distribuição de escolas por faixa de absenteísmo e o desempenho por tamanho de turma. Por serem dados anonimizados e estáveis, os mesmos marts podem ser conectados em um clique ao Looker Studio (nativo do BigQuery).



Figura 1. Cabeçalho, faixa de KPIs da rede e início dos gráficos de frequência.



Figura 2. As duas frequências, faixas de absenteísmo, desempenho por tamanho de turma e média por disciplina.

Os números do painel vêm do dataset `rmi_dev_marts` no BigQuery. A consolidação está em `docs/painel/exportar_consolidado.py` e o painel (HTML + projeto Apps Script) em `docs/painel/`.

8. Seeds, macros, testes, CI e scripts

Seed

`seeds/seed_educacao__disciplinas.csv` (CSV): de/para dos códigos de disciplina. Carregado no warehouse pelo `dbt seed`.

disciplina_codigo	disciplina_nome
disciplina_1	Português
disciplina_2	Ciências
disciplina_3	Inglês
disciplina_4	Matemática

Macros

Arquivo	O que faz
macros/nome_disciplina.sql	Traduz disciplina_1..4 para nome legível (reuso/DRY no SQL)
macros/generic_tests/test_proporcao_nulos_abaixo_de.sql	Teste genérico customizado: tolera uma fração de nulos e avisa se piorar

Testes de regra de negócio (tests/)

Teste	Regra verificada	Passa quando
assert_periodo_frequencia_coerente	data_inicio nunca maior que data_fim	Nenhuma linha retornada
assert_aluno_frequencia_sem_duplicatas	Grão da frequência único após dedup	Nenhuma linha retornada
assert_todo_aluno_com_nota_tem_matricula	Nota exige matrícula correspondente	Nenhuma linha retornada

Além desses, os `schema.yml` trazem dezenas de testes genéricos (unique, not_null, accepted_values, relationships, accepted_range, unique_combination_of_columns).

CI e scripts

Arquivo	Papel
.github/workflows/ci.yml	Roda dbt deps + dbt build + source freshness a cada push/PR (após configurar secrets do GCP)
scripts/load_to_bigquery.py	Carrega os 5 Parquet do bucket para o dataset raw no BigQuery
scripts/load_to_bigquery.sh	Mesma ingestão usando o bq CLI

9. Decisões e achados (rastreabilidade do raciocínio)

Cada decisão de modelagem nasceu de um achado concreto na análise exploratória. Esta é a trilha do raciocínio, útil para novos insights.

Validação pelo dicionário oficial da fonte

Depois de concluir a análise, localizei o `schema.yml` oficial publicado junto aos dados (`gs://case_vagas/rmi/schema.yml`). Ele confirma, pela própria fonte, decisões que eu havia tomado por inferência: o campo de frequência da avaliação é o `campo original` de frequência do bimestre, enquanto a frequência da tabela `frequencia` é um valor derivado (`100 - faltas_disciplina / dias_letivos`); `disciplina_3` é oficialmente Língua Estrangeira (Inglês); o ano letivo original é 2025 (anonimizado para 2000); e as notas receberam jitter de ±0,2. Ou seja, o dicionário da fonte respalda o uso da frequência da avaliação como sinal de absenteísmo.

Achado nos dados	Decisão tomada
id_aluno é BYTES (hash)	Converter para hexadecimal (to_hex) no staging
turma não tem série/turno	Tratar como matrícula; mart de turma usa o tamanho
avaliacao é formato largo	UNPIVOT no staging para formato longo
Inglês (disciplina_3) 100% nula	Documentar; intermediate ignora notas nulas
Tabela frequencia sem variância (97-100%)	NÃO usar para absenteísmo; manter como contraste
Campo de frequência da avaliação varia 0-100%	Usar como fonte do absenteísmo (sinal real: ~10% dos alunos)
id_turma da frequencia com ~12% órfãos	Join por id_aluno; relationship de turma como warn
Duplicatas de grão	Dedup com row_number() no staging
bairro do aluno com ~0,07% nulos	Teste customizado tolera até 1% (warn)

Insight central para explorar mais

A existência de duas frequências (uma sem sinal, outra com sinal) foi o achado que mais mudou a entrega. Vale investigar também: desempenho por faixa etária, evolução das notas entre bimestres, e se o tamanho da turma tem relação causal ou é artefato da aleatorização.

10. O que NÃO foi feito e pendências

Execução real no BigQuery: concluída

O `dbt build` rodou de ponta a ponta no BigQuery Sandbox (projeto `exerciciodesafio`): seed, 5 views de staging, 2 marts em tabela e 63 testes, com PASS=62, WARN=1 e ERROR=0. O único WARN é o planejado (338.356 registros de frequência com turma órfã). O `dbt source freshness` passou nas 5 fontes.

A execução real revelou dois ajustes que a simulação no DuckDB não pegou, ambos por causa da tipagem estrita do BigQuery: (1) `accepted_values` em colunas numéricas (`bimestre`, `ano_letivo`) precisou de `quote: false`, pois o dbt envolve os valores em aspas e o BigQuery não compara INT64 com STRING; (2) o mart de absenteísmo não pode ter `ORDER BY`, porque é uma tabela clusterizada por `bairro_id`.

Os números do mart no BigQuery conferem com a simulação: 10,41% de absenteísmo crônico geral, 478 escolas com 20 ou mais alunos, média de 10,49% e faixa de 0% a 33,3%.

Pendência remanescente

- CI no GitHub Actions: o workflow está pronto, mas só roda de fato depois de cadastrar os secrets `GCP_PROJECT` e `GCP_SA_KEY` (service account) no repositório.

Itens deixados de fora de propósito

- Materialização incremental na frequencia (fica como table): proposto para produção por ser a maior tabela.
- Snapshots (SCD2) para histórico de aluno mudando de turma/escola.
- Data contracts (contract: enforced) nos marts.
- Hooks (pre/post-hook).
- Testes do dbt_expectations e uso do codegen (pacotes declarados, não explorados em testes).
- Cruzamento com a tabela pública de bairros (datario): os bairros estão em hash, não conciliam.

Ressalvas de interpretação

- Os dados são anonimizados e aleatorizados: números servem para avaliar a técnica, não para conclusões reais sobre a rede.
- No absenteísmo, a frequência vem do campo de frequência da avaliação, mas a escola/região vem da tabela frequencia (única com escola e que concilia 100%). Essa junção está documentada.
- A escola do aluno foi definida por heurística (escola predominante), na ausência de um vínculo oficial.

Anexo: como os números foram verificados

Para garantir que as análises refletem a fonte, e não uma tabela gerada por mim:

- **Checksum:** o MD5 da cópia local de cada Parquet confere com o MD5 que o Google Cloud reporta para o objeto no bucket (mesmo hash e mesmo tamanho em bytes).
- **Leitura direta:** as estatísticas de frequência foram reproduzidas lendo o arquivo direto da URL do bucket (via httpfs do DuckDB), sem passar por cópia local, com resultado idêntico.
- **Simulação da lógica:** o pipeline de staging/intermediate/marts foi reproduzido em DuckDB para validar contagens e amostras (as deste documento) antes de rodar no BigQuery.
- **Execução real:** o `dbt build` no BigQuery reproduziu as mesmas contagens das tabelas brutas (97.044 alunos, 1.558 escolas, 221.687 avaliações, 2.727.684 registros de frequência) e os mesmos indicadores do mart de absenteísmo.

Resumo de contagens por model (linhas):

Model	Linhas
stg_educacao__alunos	97.044
stg_educacao__escolas	1.558
stg_educacao__matriculas	97.044
stg_educacao__frequencia	2.725.108
stg_educacao__avaliacoes	886.612
int_educacao__aluno_frequencia	97.044
int_educacao__aluno_desempenho	58.374
mart_educacao__absenteismo_regiao	521
mart_educacao__desempenho_por_turma	17.311

Fim do documento de rastreio.